PERAMALAN PASARAN SAHAM SYARIKAT TOP GLOVE MALAYSIA MENGGUNAKAN KAEDAH PEMBELAJARAN MESIN

ZATIL HIDAYAH BINTI ASRUL AZHAR

UNIVERSITI KEBANGSAAN MALAYSIA

PERAMALAN PASARAN SAHAM SYARIKAT TOP GLOVE MALAYSIA MENGGUNAKAN KAEDAH PEMBELAJARAN MESIN

ZATIL HIDAYAH BINTI ASRUL AZHAR

PROJEK PENYELIDIKAN YANG DIKEMUKAKAN UNTUK MEMENUHI SEBAHAGIAN DARIPADA SYARAT MEMPEROLEH IJAZAH SARJANA MUDA SAINS DENGAN KEPUJIAN (MATEMATIK)

FAKULTI SAINS DAN TEKNOLOGI
UNIVERSITI KEBANGSAAN MALAYSIA
BANGI

2022

PENGAKUAN

Saya akui karya ini adalah hasil kerja saya sendiri kecuali nukilan dan ringkasan yang tiap-tiap satunya telah saya jelaskan sumbernya.

17 Februari 2022

ZATIL HIDAYAH BINTI
ASRUL AZHAR
A168895

PENGHARGAAN

Bersyukur Alhamdulillah kepada Allah S.W.T kerana saya dapat melaksanakan dan menyiapkan kajian ilmiah ini dalam tempoh yang telah diberikan.

Pertama sekali, saya ingin menyatakan jutaan terima kasih kepada penyelia saya iaitu Dr. Sakhinah Abu Bakar di atas kesudian beliau meluangkan dan memberikan sokongan memberikan panduan bermula daripada pemilihan tajuk sehingga perangkaan kajian saya serta dan memberikan pendapatan dan pengetahuan sepanjang proses penyiapan kajian ilmiah ini meskipun Dr. mempunyai komitmen yang lain.

Sekalung jutaan terima kasih yang tidak terhingga juga saya ucapkan kepada kedua-dua ibu bapa saya yang tidak pernah putus memberikan sokongan sehingga saya berjaya menyiapkan laporan ilmiah ini. Tidak lupa juga kepada rakan-rakan yang memberi bantuan dan pendapat sepanjang penyiapan kajian ilmiah ini.

ABSTRAK

Pelaburan adalah ekonomi utama bagi setiap negara dalam pasaran saham menyebabkan minat terhadap bidang pasaran saham semakin meningkat. Kajian ini membincangkan tentang perbandingan kaedah yang berbeza untuk meramal harga saham Malaysia dengan menggunakan kaedah pembelajaran mesin. Indeks pasaran saham Top Glove Corporation Berhad akan digunakan dalam kajian ini. Pandemik Covid-19 telah melanda sejak tahun 2020 sehingga kini yang menyebabkan permintaan kepada produk syarikat Top Glove semakin meningkat. Maka, Top Glove adalah syarikat yang memainkan peranan yang besar semasa pandemik di Malaysia. Data harga saham Top Glove telah dikumpul daripada platform pasaran kewangan. Peramalan ini akan dilakukan dengan menggunakan kaedah Rangkaian Neural Rambatan Kebelakang (BNN) dan Memori Jangka Panjang Pendek (LSTM) bagi mencapai objektif kajian. Akhir sekali, keputusan akhir dalam kajian ini menunjukkan bahawa kaedah LSTM lebih tepat berbanding kaedah BNN.

TOP GLOVE MALAYSIA STOCK MARKET PREDICTION USING MACHINE LEARNING

ABSTRACT

Investment is the main economy for every country in the stock market causing increase the interest in the field of stock market. This study discusses the comparison of different methods to predict Malaysia stock price by using machine learning method. The stock market index of Top Glove Corporation Berhad will be used in this study. The Covid-19 pandemic has been raging since 2020 till now, which has caused to increase the demand for Top Glove company's products. That's why, Top Glove is very important during the pandemic in Malaysia. Top Glove stock price data was collected from the financial market platform. This prediction will be done by using Backward Propagation Neural Network (BNN) and Long-Short Term Memory (LSTM) method to achieve the objectives of the study. Finally, the final results in this study indicate that the LSTM is more accurate than BNN method.

KANDUNGAN

Halaman

PENGAKUAN		**ii**
PENGHARGAAN		**iii**
ABSTRAK		**iv**
ABSTRACT		**v**
KANDUNGAN		**vi**
SENARAI JADUAL		**viii**
SENARAI ILUSTRASI		**ix**
BAB I	**PENGENALAN**	
1.1	Pendahuluan	1
	1.1.1 Syarikat Top Glove Corporation Bhd	2
1.2	Permasalahan Kajian	3
1.3	Skop Kajian	3
1.4	Objektif Kajian	5
1.5	Organisasi Laporan	5
BAB II	**KAJIAN PERPUSTAKAAN**	
2.1	Pengenalan	6
2.2	Kajian Perpustakaan	6
BAB III	**KAEDAH KAJIAN**	
3.1	Pengenalan	9
3.2	Set Data	9
	3.2.1 Pemboleh Ubah Baharu	10
3.3	Rangkaian Neural	10
	3.3.1 Turun Cerun	11
	3.3.2 Rambatan Kebelakang	12
3.4	Rangkaian Neural Berulang	14
	3.4.1 Memori Jangka Pendek yang Panjang	14
3.5	Pengukuran Penilaian	17

BAB IV	**DAPATAN KAJIAN**	
4.1	Pengenalan	18
4.2	Hasil Ramalan Rangkaian Rambatan Kebelakang	19
4.3	Hasil Ramalan Rangkaian Memori Jangka Pendek yang Panjang	20
4.4	Perbandingan Antara Rambatan Kebelakang dan Memori Jangka Pendek yang Panjang	22
BAB V	**KESIMPULAN DAN CADANGAN**	
5.1	Pengenalan	25
5.2	Kesimpulan	25
5.3	Cadangan	26
RUJUKAN		**27**
Lampiran A	Pengaturcaraan Komputer	30

SENARAI JADUAL

No. Jadual		Halaman
Jadual 3.1	Statistik set data	9
Jadual 4.1	Sebahagian set data perbandingan harga saham asal dengan ramalan menggunakan kaedah BNN	19
Jadual 4.2	Matriks kekeliruan bagi BNN	20
Jadual 4.3	Prestasi penilaian keputusan BNN	20
Jadual 4.4	Sebahagian set data perbandingan harga saham asal dengan ramalan menggunakan kaedah LSTM	21
Jadual 4.5	Matriks kekeliruan bagi LSTM	22
Jadual 4.6	Prestasi penilaian keputusan LSTM	22
Jadual 4.7	Perbandingan ketepatan peramalan harga saham menggunakan kaedah BNN dan LSTM	23

SENARAI ILUSTRASI

No. Rajah		Halaman
Rajah 3.1	Struktur neuron komputer	11
Rajah 3.2	Struktur unit LSTM	15
Rajah 4.1	Graf harga saham syarikat Top Glove	18
Rajah 4.2	Ramalan harga saham menggunakan BNN	20
Rajah 4.3	Graf ramalan harga saham menggunakan kaedah LSTM	22
Rajah 4.4	Graf perbandingan ramalan harga saham antara BNN dan LSTM	23

BAB I

PENGENALAN

1.1 PENDAHULUAN

Pasaran saham adalah sesuatu petunjuk ketara dalam mencerminkan kesihatan ekonomi sesebuah negara. Hal ini kerana saham tersenarai dalam pasaran saham mewakili pertumbuhan syarikat di negara. Oleh itu, prestasi pasaran saham mempengaruhi prestasi syarikat-syarikat ini termasuk ekonomi negara. Prestasi purata saham ini ditunjukkan oleh indeks pasaran saham. Indeks ini mendedahkan prestasi pasaran saham sama ada meningkat, stabil atau menurun. Pelabur menggunakan pelbagai cara untuk meningkatkan kekayaan mereka iaitu dengan memahami cara pasaran berfungsi dan akses kepada alatan yang boleh digunakan untuk meramalkan trend harga pasaran dengan tepat. Oleh kerana pulangan yang menguntungkan ini, kebanyakan penyelidik telah menumpukan kerja mereka untuk meramalkan pasaran harga saham berdasarkan parameter pasaran saham seperti harga saham tutup, indeks pasaran saham, trend kenaikan dan penurunan (Soon et al., 2018).

Pasaran saham pertama di dunia dikaitkan kembali ke Belgium. Bruges, Flanders, Ghent, dan Rotterdam di Belanda semuanya menjadi tuan rumah sistem pasaran saham mereka sendiri pada tahun 1400-an dan 1500-an. Walau bagaimanapun, pada umumnya diterima bahawa Antwerp mempunyai sistem pasaran saham pertama di dunia. Antwerp adalah pusat komersial Belgium dan ia adalah rumah kepada keluarga Van der Beurze yang berpengaruh. Akibatnya, pasaran saham awal dipanggil Beurzen. Semua pasaran saham awal ini mempunyai satu perkara yang berkurang iaitu saham. Walaupun infrastruktur dan institusi menyerupai pasaran saham hari ini, tiada siapa yang benar-benar berdagang saham syarikat. Sebaliknya, pasaran berurusan dengan hal ehwal kerajaan, perniagaan, dan hutang individu. Sistem dan organisasi

adalah serupa, walaupun hartanah sebenar yang didagangkan adalah berbeza (BeBusinessed, 2019).

1.1.1 Syarikat Top Glove Corporation Bhd

Top Glove Corporation Bhd telah ditubuhkan pada tahun 1991 di Malaysia. Seterusnya, syarikat Top Glove telah berkembang daripada kilang tunggal dengan satu barisan pengeluaran sarung tangan menjadi pengeluar sarung tangan terbesar di dunia. Memegang 26 peratus bahagian pasaran dunia untuk sarung tangan getah, Top Glove menyampaikan sarung tangan untuk melindungi nyawa di setiap sudut dunia dengan operasi di Malaysia, Thailand, Vietnam, China, Amerika Syarikat, Jerman dan Brazil. Syarikat tersebut mengeksport lebih 2,000 kepada 195 negara di seluruh dunia (Top Glove (Top Glove Corporation Bhd, 2022).

Top Glove menghasilkan sarung tangan berkualiti tinggi secara konsisten dan mempunyai kos yang cekap dan rendah. Pengeluar sarung tangan komprehensifnya terdiri daripada lateks, vinil dan nitril, sarung tangan pembedahan , sarung tangan isi rumah, sarung tangan industri, sarung tangan polietilena tuang (CPE) dan sarung tangan elastomer termoplastik (TPE). Produk Top Glove adalah item yang penting dalam industri penjagaan kesihatan bagi memastikan kebersihan terjaga (MATRADE, 2021).

Sepanjang 20 tahun yang lalu, Top Glove telah menunjukkan pertumbuhan yang stabil dengan kadar pertumbuhan tahunan kompaun (CAGR) sebanyak 27 peratus untuk hasil dan 36 peratus untuk keuntungan selepas cukai (PAT). Pada masa ini, Top Glove mempunyai saham komponen Indeks Standard Global MSCI, Indeks KLCI FTSE Bursa Malaysia, Indeks 100 Teratas FBM, Indeks FBM Emas, Indeks FBM Hijrah Syariah, Indeks FBM Emas Syariah dan Indeks Kemampanan Dow Jones (DJSI) untuk Pasaran Memuncul. Pada tahun 2021, Top Glove juga termasuk Forbes Global 2000 dan merupakan satu-satunya syarikat sarung tangan Malaysia dalam senarai berprestij (Bursa Digital Research, 2021).

1.2 PERMASALAHAN KAJIAN

Pasaran saham dunia sangat tidak menentu pada tahun 2020 disebabkan oleh pandemik Covid-19. Malaysia merupakan antara pasaran utama Asia Tenggara yang berjaya menarik pelabur menyertai pelaburan semasa pandemik dan menyebabkan jumlah urus niaga melonjak dan memecahkan rekod tertinggi sekitar 20 bilion unit sehari pada Ogos berbanding purata sekitar 3 hingga 5 bilion unit sebelum ini (Chuan et al., 2021). Pelaburan adalah sesuatu yang tidak boleh dijangka, sesetengah pedagang mendapat keuntungan. Namun kerugian tetap akan ditimpa dengan begitu sahaja. Kajian ini akan dijalankan bagi menambah pengetahuan dan memahami pendekatan yang penting dalam membuat peramalan harga saham untuk meramal harga saham Top Glove bagi tempoh 4 tahun iaitu bermula 1 Jun 2018 hingga 30 Jun 2021.

Pelbagai data berstruktur dan tidak berstruktur dijana setiap hari daripada pasaran saham di seluruh dunia, meningkatkan jumlah (*volume*), halaju, kepelbagaian (*variety*) dan kebenaran (*veracity*) data pasaran saham, dan menjadikan ia rumit untuk dianalisis. Dalam menganalisis data besar dari pasaran saham ini, dua kaedah telah diterima secara umum, iaitu: analisis asas dan analisis teknikal. Analisis asas memberi tumpuan kepada trend ekonomi persekitaran tempatan dan antarabangsa, sentimen awam, penyata kewangan dan aset yang dilaporkan oleh syarikat, keadaan politik dan persatuan syarikat di seluruh dunia. Analisis teknikal adalah berdasarkan analisis statistik, menggunakan pergerakan harga saham. Penunjuk teknikal seperti purata bergerak, silang mati (*dead cross*) dan silang emas (*golden-cross*) digunakan untuk keputusan dagangan saham yang berkesan. Walaupun teknik ini telah wujud, analisis pasaran saham masih mencabar dan terbuka (Nti et al., 2020).

1.3 SKOP KAJIAN

Pandemik Covid-19 telah melanda sejak tahun 2020 sehingga kini yang menyebabkan permintaan kepada produk syarikat Top Glove semakin meningkat. Syarikat Top Glove adalah antara syarikat pembuat sarung tangan getah terbesar di Malaysia (Mung, 2021). Maka, Top Glove adalah syarikat yang memainkan peranan yang besar semasa pandemik di Malaysia. Oleh itu, indeks pasaran saham Top Glove Corporation Berhad akan digunakan dalam kajian ini.

Dalam literatur kewangan, kaedah ramalan harga dikelaskan kepada empat kumpulan iaitu kaedah analisis teknikal, analisis asas dan ramalan berdasarkan siri masa dan pembelajaran mesin. Melalui penemuan corak baharu dalam data, pembelajaran mesin digunakan untuk mengenal pasti fungsi asas berdasarkan data yang dibentuk dan merealisasikan model linear dan bukan linear yang wujud dalam data ini. Pada tahun-tahun lepas, algoritma seperti rangkaian neural buatan dan mesin vektor sokongan (SVM) digunakan secara meluas untuk ramalan siri kewangan dan pencapaian ketepatan tinggi dalam peramalan. Hasil kajian menunjukkan kelebihan yang tinggi dengan menggunakan kaedah tersebut berbanding kaedah tradisional dalam ramalan harga saham. Oleh itu, di kebanyakan negara, seperti Amerika Syarikat, Jerman, Perancis dan Belanda, penyelidik telah berjaya meramalkan tingkah laku pasaran saham melalui pelbagai kaedah pembelajaran mesin. Kaedah pembelajaran mesin sering dianggap sebagai submedan kecerdasan buatan (Nikou et al., 2019).

Dalam kajian ini, kaedah Rangkaian Neural Rambatan Kebelakang (BNN) dan Rangkaian memori jangka pendek yang panjang (LSTM) digunakan dalam meramalkan harga penutupan saham syarikat Top Glove dibandingkan dan dianalisis. Saham Top Glove dipilih kerana turun naik harganya. Top Glove terkenal dengan pengeluar sarung tangan getah di Malaysia. Ia telah berkembang menjadi antara pengeluar yang paling besar di dunia dan disenaraikan di Bursa Saham Kuala Lumpur (Top Glove, 2021). Kebanyakan kajian terdahulu menggunakan harga penutupan lepas untuk meramalkan harga penutupan masa hadapan (Soon et al., 2018). Dalam kajian ini, parameter baharu digunakan daripada set data pasaran saham Top Glove yang akan dibincangkan pada bahagian bab tiga dan empat untuk meningkatkan ketepatan ramalan. Eksperimen telah dijalankan dan hasilnya dianalisis untuk menentukan seni bina rangkaian neural yang memberikan ketepatan ramalan harga saham yang lebih baik.

1.4 OBJEKTIF KAJIAN

Kajian ini terdiri daripada dua objektif iaitu:

1. Meramal harga saham syarikat Top Glove di Malaysia menggunakan kaedah pembelajaran mesin.
2. Membandingkan kaedah peramalan harga saham bagi Top Glove Malaysia.

1.5 ORGANISASI LAPORAN

Laporan ini disusun dengan beberapa bahagian. Bab I mengandungi pengenalan keperluan untuk pelaburan dalam pasaran saham dan menggunakan kecerdasan buatan dalam ramalan pasaran saham. Bab II memberi ulasan tentang kajian-kajian lepas yang berkaitan dengan mesin pembelajaran dalam ramalan pasaran saham. Bab III ialah ringkasan pengenalan kepada BNN dan LSTM. Bab IV membincangkan hasil kajian dengan menggunakan kaedah BNN dan LSTM, termasuk perbandingan kaedah BNN dan LSTM. Akhir sekali, Bab V merumuskan secara keseluruhan untuk kajian ini.

BAB II

KAJIAN PERPUSTAKAAN

2.1 PENGENALAN

Berdasarkan kajian Nti et al. (2020), telah menunjukkan bahawa aplikasi beberapa algoritma pembelajaran mesin yang berkuasa telah meningkatkan ketepatan klasifikasi dan ramalan harga saham dengan ketara. Oleh itu, pembelajaran mesin telah menarik perhatian penyelidik untuk meramal pasaran saham dan beberapa teknik pembelajaran mesin telah merekodkan ketepatan ramalan yang tertentu mengikut kaedah yang telah digunakan dalam kajian-kajian lepas. Berikut adalah perbincangan kajian lepas mengenai ramalan harga saham dengan menggunakan pembelajaran mesin.

2.2 KAJIAN PERPUSTAKAAN

Di dalam bahagian ini, penggunaan model rangkaian neural dalam membuat peramalan harga saham akan dibincangkan. Berdasarkan kajian Islam dan Nguyen (2020), kajian yang pertama membina model rangkaian neural untuk ramalan harga saham telah dilakukan oleh White (1988). Model ramalannya adalah berdasarkan saham harian IBM dan ramalan latihan adalah sangat optimistik. Kemudian, banyak penyelidikan telah dilakukan untuk menyemak ketepatan ramalan rangkaian neural untuk meramalkan pasaran saham.

Banyak kajian yang melibatkan perbandingan kaedah ARIMA dengan kaedah rangkaian neural buatan. Antaranya, Adebiyi et al. (2014) dan Sagir et al. (2017) telah membandingkan kaedah regresi linear berganda (ARIMA) dan rangkaian neural buatan (ANN) dalam peramalan harga saham. Mereka telah menemukan bahawa kaedah rangkaian neural buatan lebih baik daripada kaedah ARIMA. Satu kajian kaedah

rangkaian neural buatan (ANN) untuk meramal harga saham dan trend saham telah dijalankan oleh Hasan dan Rasel (2016). Kaedah peramalan mereka berdasarkan harga saham syarikat Wal-Mart di Amerika Syarikat dan mereka telah menemui bahawa ANN dapat menghasilkan keputusan rasional dengan ralat yang kecil.

Anggreani et al. (2021) telah menganalisis ramalan data multivariat menggunakan kaedah rangkaian neural rambatan balik (BNN). Lima pemboleh ubah dan bilangan data yang berbeza telah digunakan. Mereka menemui bahawa model data ke-4 mempunyai pemboleh ubah terbesar iaitu 19 pemboleh ubah dan bilangan 392 data menunjukkan 98.718 peratus dalam masa 27.798 saat sahaja. Manakala, model data ke-3 mempunyai 13 pemboleh ubah dan bilangan data yang terbesar iaitu 589 data menunjukkan 95.385 peratus dalam masa yang lama iaitu 45.442 saat.

Moghaddam et al. (2016) menggunakan rangkaian neural buatan dalam meramal harga saham harian. Rangkaian yang telah digunakan terdapat dua jenis input iaitu empat hari prior dan sembilan hari prior. Bagi membandingkan keputusan, R-kuasa dua telah dilaksanakan sebagai ujian kejituan bagi dua jenis dataset tersebut. Begitu juga, Ruxanda et al. (2014), meramal pasaran saham dengan aplikasi indeks Romanian pasaran saham Bucharest. Keputusan terakhir beliau didapati bahawa algoritma latihan Broyden-Fletcher-Goldfarb-Shanno adalah kaedah yang ideal kerana mempunyai ralat yang lebih kecil.

Kumar dan Thenmozhi (2005) telah menjalankan beberapa kajian mengenai kecekapan setiap kaedah hutan rawak (*Random Forest*, RF), mesin vektor sokongan (SVM) dan rangkaian neural buatan yang lain dalam meramal indeks kadar S&P CNX NIFTY dan membanding antara tiga kaedah fungsi tak linear dan satu kaedah fungsi linear. Keputusan menunjukkan SVM dapat memberikan hasil yang lebih tepat. Zhang, Shi, Zhang dan Shi (2006) meramal trend pertukaran harga saham Shanghai menggunakan SVM dan membuat kesimpulan bahawa SVM mempunyai keupayaan yang tinggi sebagai peramalan. Serta model gabungan SVM dan model pintar mempunyai hasil yang lebih baik daripada model SVM. Kajian Vijh et al. (2020) telah menggunakan teknik rangkaian neural buatan dan hutan rawak untuk harga tutup (*closing*) saham bagi lima syarikat yang berbeza industri. Kaedah tersebut dinilai

menggunakan ralat punca min kuasa dua (RMSE) dan min peratusan ralat mutlak (MAPE), dan keputusan kajian ini menunjukkan kaedah ANN lebih baik daripada RF.

Gao (2016) meramalkan pasaran saham menggunakan rangkaian neural berulang (RNN) melalui memori jangka pendek yang panjang (LSTM). Kajian ini bertujuan untuk mengkaji ketersauran dan kecekapan LSTM dalam ramalan pasaran saham. Berdasarkan hasil kajian, ketepatan purata model LSTM dalam meramal enam saham adalah 54.83%, dengan ketepatan tertinggi dan terendah masing-masing adalah 59.5% dan 49.75%. Kajian peramalan harga saham siri masa oleh Chen et al. (2018) menggunakan beberapa kaedah seperti pembelajaran mendalam dan tiga rangkaian neural buatan iaitu rangkaian neural rambatan kebelakang, mesin pembelajaran ekstrem dan rangkaian neural fungsi asas jejari. Didapati bahawa jumlah data meningkatkan prestasi ramalan. Ini menunjukkan bahawa pembelajaran mendalam mengenal pasti ciri-ciri data transaksi yang tidak linear dan berfungsi sebagai alat ramalan indeks saham yang tepat untuk melabur pasaran kewangan.

Dalam kajian Nikou et al. (2019) meramal harga saham dengan aplikasi algoritma pembelajaran mendalam dan membandingkan dengan algoritma pembelajaran mesin. Keputusan yang diperoleh menunjukkan kaedah pembelajaran mendalam adalah kaedah yang terbaik untuk membuat peramalan. Oleh itu, peramalan harga saham berdasarkan kajian lepas dapat meramal dengan menggunakan pelbagai kaedah dan kaedah yang lebih tepat untuk meramal adalah dengan menggunakan kaedah rangkaian memori jangka pendek yang panjang.

BAB III

KAEDAH KAJIAN

3.1 PENGENALAN

Bab ini membincangkan kaedah yang akan digunakan untuk mencapai objektif kajian iaitu meramal harga saham syarikat Top Glove di Malaysia menggunakan kaedah pembelajaran mesin dan membandingkan kaedah peramalan harga saham bagi Top Glove Malaysia. Bab ini juga akan menerangkan kaedah kajian peramalan yang dijalankan bermula daripada sumber data, formula berkaitan dan seterusnya kaedah mengalisis data.

3.2 SET DATA

Data harga saham Top Glove Corporation Berhad telah dikumpulkan daripada laman sesawang pasaran kewangan (www.investing.com) yang menyediakan data masa nyata, carta, alat kewangan, berita gempar dan analisis pasaran kewangan. Rangka masa bagi pengumpulan data sejarah adalah bermula dari 1 Jun 2018 hingga 30 Jun 2021. Jumlah data yang digunakan adalah sebanyak 755 data.. Data harian pasaran merangkumi 7 fitur iaitu Harga (Price), Harga Buka (Open), Harga Tinggi (High), Harga Rendah (Low), Kuantiti (Volume) dan Peratus Perubahan (Change%). Jadual 3.1 menunjukkan statistik set data yang digunakan untuk latihan sebanyak 80 peratus dan ujian sebanyak 20 peratus.

Jadual 3.1 Statistik set data

	Set Data	**Data Latihan**	**Data Ujian**
Masa	1/6/2018 – 30/6/2021	1/6/2018 – 25/11/2020	26/11/2020 – 30/6/2021

3.2.1 Pemboleh Ubah Baharu

Enam pemboleh ubah baharu yang dibina sebagai peramalan harga penutup saham. Model latih akan menggunakan set data pemboleh ubah baharu ini. Pemboleh ubah adalah seperti berikut (Vijh et al., 2020):

1. Harga saham Tinggi tolak Rendah (H-L)
2. Harga saham Tutup (Close) tolak Buka (Open) (O-C)
3. Tiga hari harga saham purata bergerak (3 HARI MA)
4. Sepuluh hari harga saham purata bergerak (10 HARI MA)
5. Tiga puluh hari harga saham purata bergerak (30 HARI MA)
6. Sisihan piawai bagi masa lima hari (STD DEV)

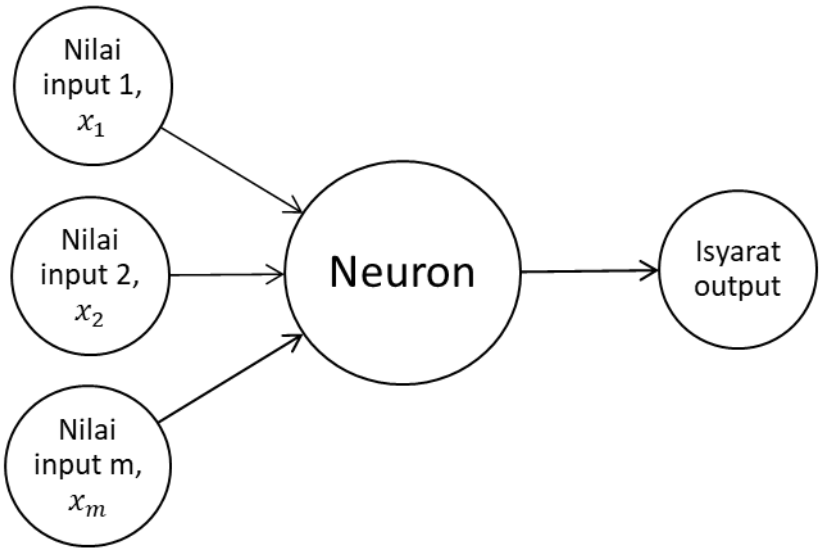
3.3 RANGKAIAN NEURAL

Kajian Rangkaian Neural telah dimulakan untuk memetakan otak manusia dan memahami cara manusia mengambil keputusan tetapi algoritma mencuba untuk menghapuskan emosi manusia termasuk daripada aspek perdagangan. Namun, otak manusia berkemungkinan mempunyai mesin yang paling kompleks di dunia ini dan telah diketahui agak berkesan untuk membuat kesimpulan dalam masa yang singkat (Singh, 2019).

Struktur neuron mempunyai tiga komponen iaitu neuron, dendrite dan akson. Badan utamanya adalah neuron, manakala dendrite adalah penerima isyarat dan akson adalah penghantar. Satu neuron sahaja tidak banyak digunakan kerana ia boleh melakukan tugasan yang mudah. Namun, apabila ia bersambung dengan neuron lain, ia dapat melakukan pengiraan dan mengendalikan mesin yang rumit iaitu badan manusia (Singh, 2019).

Daripada perspektif neuron komputer, ia dibina dengan cara yang sama seperti yang ditunjukkan dalam Rajah 3.1. Terdapat beberapa nilai input pada neuron kemudian neuron akan mengeluarkan isyarat sebagai output selepas pengiraan. Lapisan input menyerupai dendrite dan isyarat output adalah akson. Setiap isyarat input diberikan

pemberat, w_i. Pemberat ini didarab dengan nilai input dan neuron yang menyimpan jumlah nilai pemboleh ubah pemberat. Pemberat ini dikira dalam fasa latihan pembelajaran rangkaian neural melalui konsep turun cerun (*gradient descent*) dan rambatan belakang (*back propagation*).



Rajah 3.1 Struktur neuron komputer

(Sumber: Singh 2019)

Fungsi pengaktifan akan digunakan pada jumlah pemberat yang menghasilkan isyarat output neuron. Isyarat input dijana oleh output neuron lain, dengan cara ini rangkaian dibina untuk membuat ramalan. Oleh itu, cara tersebut adalah idea asas rangkaian neural.

3.3.1 Turun Cerun

Turun cerun melibatkan analisis fungsi kos kecerunan lengkung. Berdasarkan kecerunan, pemberat dilaraskan untuk mengurangkan fungsi kos dalam beberapa langkah daripada mengira nilai untuk semua kemungkinan penggabungan.

Terdapat tiga turun cerun yang boleh laksanakan iaitu turun cerun kelompok (batch gradient descent), turun cerun stokastik (stochastic gradient descent) dan turun cerun kelompok mini (mini-batch gradient descent). Dalam turun cerun kelompok,

fungsi kos dikira dengan menjumlahkan setiap fungsi kos dalam set data latihan. Seterusnya, mengira kecerunan dan melaraskan pemberat (Singh, 2019).

Seterusnya dalam turun cerun stokastik, kecerunan fungsi kos dan pelarasan berat dilakukan selepas setiap kemasukan data dalam set data latihan. Ia sangat berguna untuk mengelak daripada tersekat di minimum setempat, jika lengkung fungsi kos tidak cembung tegas. Setiap kali menjalankan turun cerun stokastik, proses untuk mencapai minimum global akan berbeza. Turun cerun kelompok boleh mengakibatkan terperangkap dengan penyelesaian suboptimum, jika ia berhenti di minimum setempat (Sidhpuri, 2021).

Kemudian, turun cerun kelompok mini yang merupakan gabungan kaedah kelompok dan stokastik. Kelompok yang berbeza dicipta dengan menggabungkan beberapa pemasukan data dalam satu kelompok. Hal ini, menghasilkan pelaksanaan turun cerun stokastik pada kumpulan pemasukan data yang lebih besar dalam set data latihan (Oppermann, 2020).

3.3.2 Rambatan Kebelakang

Rambatan kebelakang (BNN) adalah antara algoritma latihan ANN yang paling popular untuk ramalan siri masa kewangan. Rangkaian neural rambatan belakang - buatan (BNN-ANN) dicirikan oleh ralat rambatan belakang. BNN menggunakan kaedah turun cerun untuk meminimumkan fungsi ralat dalam ruang pemberat. Fungsi ralat perlu selanjar dan terbezakan kerana kaedah latihan ini memerlukan pengiraan kecerunan fungsi ralat dalam setiap lelaran. Gabungan berat yang meminimumkan fungsi ralat dianggap sebagai penyelesaian masalah pembelajaran (Rajihy et al., 2017).

Latihan BP-ANN adalah seperti berikut (Liu & Wang, 2011):

Andaikan $Inp(n)$ dan $Out(n)$ masing-masing sebagai input dan output sepadan dengan nod n:

$$Inp_n = \sum_m w_{mm}\, Out_m \qquad \ldots(3.1)$$

$$Out_n = f(Inp_n + \beta_n) \quad \ldots(3.2)$$

dengan w_{mm} adalah pemberat sambungan daripada nod ke-*m* dalam lapisan sebelumnya kepada nod n, dan

$$f(net) = \left(\frac{2}{1 - e^{2net}}\right) - 1 \quad \ldots(3.3)$$

sebagai fungsi pengaktifan nod ('net' mewakili input bersih neuron). Fungsi yang memperkenalkan bukan linear ke dalam output neuron adalah antara fungsi sigmoid iaitu fungsi pengaktifan yang paling popular dalam BNN-ANN, manakala β_n adalah input pincang ke nod iaitu pemberat sambungan daripada unit khas dengan nilai pengaktifan malar dan bukan sifar (Rajihy et al., 2017).

Ralat E dalam output dikira seperti berikut:

$$E = \frac{1}{2N} \sum_N \sum_o \left(P_{N_o} - Out_{N_o}\right)^2 \quad \ldots(3.4)$$

yang N dan o masing-masing menandakan bilangan elemen dalam set data latihan dan bilangan neuron dalam lapisan output manakala P_{N_o} dan Out_{N_o} masing-masing mewakili sasaran dan nilai output (Rajihy et al. 2017). Latihan berakhir apabila ralat E jatuh bawah ambang atau tahap toleransi. Ralat e_o dalam lapisan output dan ralat e_n dalam lapisan tersembunyi dikira seperti berikut:

$$e_o = \lambda(P_o - Out_o) f'(Out_o) \quad \ldots(3.5)$$

$$e_n = \lambda \sum_m e_o \, w_{mm} \, f'(Out_n) \quad \ldots(3.6)$$

yang P_o, Out_o, Out_n dan λ masing-masing mewakili output jangkaan bagi nod output ke-*o*, output sebenar dalam lapisan output, nilai output sebenar dalam lapisan tersembunyi dan pemboleh ubah terlaraskan dalam fungsi pengaktifan. Perhatikan bahawa f' menandakan terbitan f. Pemberat dan pincang dalam kedua-dua lapisan

output dan tersembunyi dikemas kini melalui ralat rambatan kebelakang. Pemberat w_{nm} dan pincang $\beta(n)$ dilaraskan mengikut persamaan berikut:

$$w_{nm}(k+1) = w_{nm}(k) + \gamma\, e_o\, Out_m \quad \ldots(3.7)$$

$$\beta_m(k+1) = \beta_m(k) + \gamma\, e_m \quad \ldots(3.8)$$

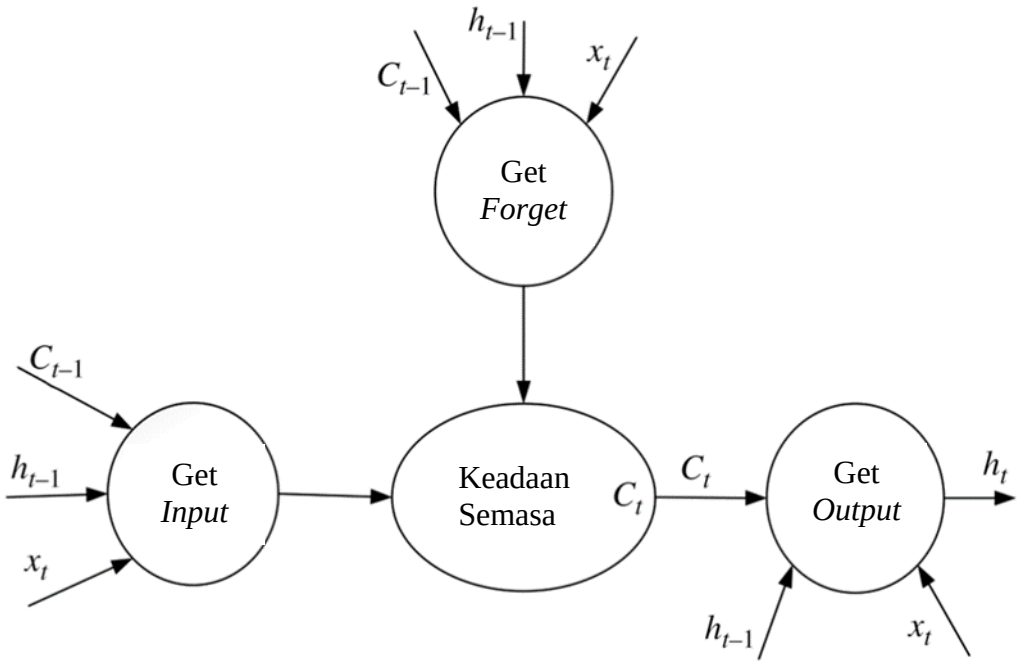
yang k dan γ masing-masing mewakili bilangan lelaran dan kadar pembelajaran.

3.4 RANGKAIAN NEURAL BERULANG

Rangkaian neural berulang (RNN) adalah sistem dinamik dan mempunyai keadaan dalaman pada setiap langkah pengelasan. Hal ini disebabkan oleh sambungan membulat antara neuron lapisan atas dan bawah dan juga hubungan pilihan sambungan maklum balas kendiri (*optional self-feedback connections*). Sambungan maklum balas ini membolehkan RNN menyebarkan data daripada peristiwa terdahulu kepada langkah pemprosesan semasa. Oleh itu, RNN membina memori peristiwa siri masa (Staudemeyer & Morris, 2019).

3.4.1 Memori Jangka Pendek yang Panjang

Rangkaian memori jangka pendek yang panjang (LSTM) ialah bentuk tertentu rangkaian neural berulang (RNN), yang merupakan istilah umum bagi siri rangkaian saraf yang mampu memproses data berjujukan. LSTM adalah struktur rangkaian khas dengan tiga struktur get (*gate*) yang ditunjukkan dalam Rajah 3.2. Tiga get diletakkan dalam unit LSTM yang dipanggil sebagai get input, get forget, dan get output. Apabila maklumat memasuki rangkaian LSTM, ia boleh dipilih mengikut peraturan. Hanya maklumat yang mematuhi algoritma yang akan ditinggalkan manakala maklumat yang tidak mematuhi akan dilupakan melalui get forget (Ding & Qin, 2020).



Rajah 3.2 Struktur unit LSTM

(Sumber: Ding & Qin 2020)

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad \ldots(3.9)$$

$$\tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}} \quad \ldots(3.10)$$

Get membenarkan maklumat dihantar secara terpilih dan Persamaan 3.9 menunjukkan fungsi pengaktifan lalai bagi rangkaian LSTM iaitu fungsi sigmoid. LSTM boleh menambah dan menghapus maklumat bagi neuron melalui unit get. Ia terdiri daripada lapisan rangkaian neural sigmoid dan operasi pendaraban untuk menentukan sama ada maklumat tersebut lulus atau tidak,. Setiap unsur output dengan lapisan sigmoid adalah nombor nyata antara [0, 1] yang mewakili pemberat yang melaluinya maklumat yang sepadan. Dalam LSTM, terdapat juga lapisan yang mengandungi fungsi pengaktifan tanh yang ditunjukkan dalam Persamaan 3.10. Ia digunakan untuk mengemas kini keadaan neuron (Ding & Qin, 2020).

Lapisan get *forget* rangkaian memori jangka pendek yang panjang menentukan maklumat yang perlu dibuang iaitu h_{t-1} dan x_t. Nilai output antara sifar dan satu bagi setiap nilai dalam keadaan neuron C_{t-1}. Satu mewakili simpan sepenuhnya manakala sifar mewakili hapuskan sepenuhnya (Olah, 2015). Persamaan 3.11 menunjukkan kaeadah pengiraan untuk *forget* kebarangkalian

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right) \quad \ldots(3.11)$$

yang h_{t-1} mewakili output neuron sebelumnya dan x_t adalah input neuron semasa. σ adalah fungsi sigmoid dan b_f adalah bias pada get *forget*.

Get *input* menentukan bilangan maklumat baharu yang ditambahkan pada keadaan neuron. Pertama, lapisan input yang mengandungi fungsi pengaktifan sigmoid menentukan maklumat yang perlu dikemas kini. Kemudian, lapisan tanh mencipta vektor nilai calon baharu, $\tilde{C}_t$ kemas kini dibuat kepada keadaan (*state*) neuron, seperti yang ditunjukkan dalam Persamaan 3.12 (Ding & Qin, 2020).

$$C_t = f_t * C_{t-1} + i_t * \hat{C}_t \quad \ldots(3.12)$$

yang kaedah pengiraan i_t dan $\hat{C}_t$ ditunjukkan dalam Persamaan 3.13 dan 3.14.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad \ldots(3.13)$$

$$\hat{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad \ldots(3.14)$$

Get *output* digunakan untuk mengawal bilangan keadaan unit neural semasa dan bilangan keadaan unit kawalan yang perlu ditapis seperti ditunjukkan dalam Persamaan 3.15 dan 3.16 (Song, 2018).

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad \ldots(3.15)$$

$$h_t = O_t * \tanh(C_t) \quad \ldots(3.16)$$

3.5 PENGUKURAN PENILAIAN

Kaedah BNN dan LSTM akan dinilai menggunakan ralat punca min kuasa dua (RMSE) dan min peratusan ralat mutlak (MAPE) untuk menentukan prestasi ramalan. Berikut adalah formula untuk menghitung RMSE dan MAPE:

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n}(O_i - F_i)^2}{n}} \quad \ldots(3.17)$$

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\frac{(O_i - F_i)}{O_i} * 100 \quad \ldots(3.18)$$

yang O_i mewakili harga asal, F_i mewakili harga yang diramalkan dan n mewakili jumlah saiz data ujian.

Seterusnya, Bab IV akan membincangkan perbandingan hasil peramalan dan menentukan ketepatan antara kaedah BNN dan LSTM.

BAB IV

DAPATAN KAJIAN

4.1 PENGENALAN

Bab ini membincangkan hasil dapatan yang dijalankan menggunakan data dan kaedah yang telah dinyatakan dalam bab tiga. Kajian ini bertujuan bagi mendapatkan perbandingan kaedah Rangkaian Neural Rambatan Kebelakang dan Memori Jangka Pendek yang Panjang bagi meramal harga saham syarikat Top Glove. Rajah 4.1 menunjukkan graf harga saham syarikat Top Glove bagi tahun 2018 hingga 2021. Data ini dianalisis dengan menggunakan perisian Python dan dihuraikan seperti penerangan selanjutnya.



Rajah 4.1 Graf harga saham syarikat Top Glove

4.2 HASIL RAMALAN RANGKAIAN RAMBATAN KEBELAKANG

Dalam kajian ini, rangkaian rambatan kebelakang telah digunakan dan 80 peratus daripada set data untuk latihan dan 20 peratus lagi untuk menguji keputusan. Ini adalah bahagian penting dalam mana-mana algoritma pembelajaran mesin, data latihan digunakan oleh model untuk mencapai pemberat model. Set data ujian digunakan untuk melihat prestasi model pada data baharu yang akan dimasukkan ke dalam model. Set data ujian juga mempunyai nilai asal untuk memahami sejauh mana kecekapan model tersebut (Singh, 2019). Matriks kekeliruan digunakan sebagai pengukur ketepatan ramalan suatu model.

Enam neuron yang mewakili pemboleh ubah baharu daripada harga penutupan indeks Top Glove telah digunakan dalam lapisan input, fungsi pemindahan unit linear yang diperbetulkan digunakan dalam lapisan tersembunyi, dan fungsi pemindahan linear digunakan dalam lapisan output (Nikou et al., 2019). Selain itu, algoritma AdamOptimizer, fungsi kos (MSE) dan algoritma rambatan kebelakang digunakan untuk pengubahsuaian pemberat. Struktur model rangkaian lapisan tersembunyi tunggal digunakan adalah 6-10-1. Model ini mengulangi ujian dengan lelaran sebanyak 100 kali dan 64 saiz kelompok. Masa bagi memproses data bagi model ini adalah sekitar 3 saat.

Seterusnya, Jadual 4.1 menunjukkan sebahagian set data perbandingan harga saham asal dengan ramalan menggunakan kaedah BNN. Rajah 4.2 menunjukkan graf ramalan harga saham menggunakan kaedah rambatan kebelakang (BNN). Dalam Rajah 4.2, garisan berwarna biru mewakili data latihan, garisan berwarna jingga mewakili harga saham asal dan garisan berwarna hijau mewakili harga saham ramalan menggunakan kaedah BNN.

Jadual 4.1 Sebahagian set data perbandingan harga saham asal dengan ramalan menggunakan kaedah BNN

Masa	Harga Saham Asal	Ramalan BNN
26/11/2020	7.05	7.852194
27/11/2020	6.99	7.336270
30/11/2020	7.12	7.444542
1/12/2020	6.79	7.115232
2/12/2020	6.68	7.279599



Rajah 4.2 Ramalan harga saham menggunakan BNN

Prestasi model BNN ditentukan dengan pengukur ralat iaitu ralat punca min kuasa dua (RMSE) dan min peratusan ralat mutlak (MAPE). Jadual 4.2 menunjukkan matriks kekeliruan bagi BNN. Ketepatan juga digunakan yang dikira daripada matriks kekeliruan. Jadual 4.3 menunjukkan prestasi penilaian keputusan BNN iaitu RMSE adalah 0.1868, MAPE adalah 4.3474 peratus dan ketepatan bagi keseluruhan BNN adalah 88. 9655 peratus.

Jadual 4.2 Matriks kekeliruan bagi BNN

	Saham terendah	**Saham tertinggi**
Saham terendah	13	3
Saham tertinggi	62	67

Jadual 4.3 Prestasi penilaian keputusan BNN

Model	**RMSE**	**MAPE**	**Ketepatan**
BNN	0.1868	4.3474%	88.9655%

4.3 HASIL RAMALAN RANGKAIAN MEMORI JANGKA PENDEK YANG PANJANG

Model memori jangka pendek yang panjang digunakan dalam kajian ini. Dalam kaedah ini, 80 peratus data dipertimbangkan untuk latihan dan 20 peratus lagi untuk ujian.Sama

seperti kaedah BNN, enam pemboleh ubah digunakan dalam lapisan input. Selepas prapemprosesan data, seni bina rangkaian LSTM digunakan terdiri daripada empat lapisan iaitu lapisan LSTM, yang mengambil saiz kumpulan kecil daripada input dan mengembalikan keseluruhan jujukan. Lapisan Kedua, LSTM yang mengambil jujukan dari lapisan sebelumnya, tetapi hanya mengembalikan 10 nilai. Ketiga, lapisan tumpat (*dense*) dengan 10 neuron dan lapisan tumpat seterusnya yang mengeluarkan nilai peramalan. Bilangan neuron dalam lapisan pertama mestilah sama dengan saiz kumpulan kecil data input (Müller, 2020).

Setiap saiz kumpulan kecil dalam set data terdiri daripada matriks dengan 60 langkah dan tujuh pemboleh ubah. Oleh itu, lapisan input rangkaian neural berulang terdiri daripada 420 neuron. 64 saiz kelompok dan nilai lelaran sama dengan 100. Selain itu, dalam kaedah ini, algoritma AdamOptimizer telah digunakan untuk pengubahsuaian pemberat dan MSE sebagai fungsi kos. Masa bagi memproses data bagi model ini adalah sekitar 1200 saat atau 20 minit.

Seterusnya, Jadual 4.4 menunjukkan sebahagian data perbandingan harga saham asal dengan ramalan menggunakan kaedah LSTM. Rajah 4.3 menunjukkan graf ramalan harga saham menggunakan kaedah LSTM. Rajah 4.3 menunjukkan garisan berwarna biru mewakili data latihan, garisan berwarna jingga mewakili harga saham asal dan garisan berwarna hijau mewakili ramalan harga saham menggunakan kaedah LSTM.

Jadual 4.4 Sebahagian set data perbandingan harga saham asal dengan ramalan menggunakan kaedah LSTM

Masa	**Harga Saham Asal**	**Ramalan LSTM**
26/11/2020	7.05	6.422260
27/11/2020	6.99	6.703670
30/11/2020	7.12	6.606553
1/12/2020	6.79	6.658450
2/12/2020	6.68	6.436266



Rajah 4.3 Graf ramalan harga saham menggunakan kaedah LSTM

Prestasi model LSTM ditentukan juga dengan pengukur ralat iaitu ralat punca min kuasa dua (RMSE) dan min peratusan ralat mutlak (MAPE). Jadual 4.5 menunjukkan matriks kekeliruan bagi LSTM. Ketepatan juga digunakan yang dikira daripada matriks kekeliruan. Jadual 4.6 menunjukkan prestasi penilaian keputusan LSTM iaitu RMSE adalah 0.0287, MAPE adalah 3.9154 peratus dan ketepatan bagi keseluruhan LSTM adalah 93.7931 peratus.

Jadual 4.5 Matriks kekeliruan bagi LSTM

	Saham terendah	**Saham tertinggi**
Saham terendah	4	5
Saham tertinggi	60	76

Jadual 4.6 Prestasi penilaian keputusan LSTM

Model	**RMSE**	**MAPE**	**Ketepatan**
LSTM	0.0287	3.9154%	93.7931%

4.4 PERBANDINGAN ANTARA RAMBATAN KEBELAKANG DAN MEMORI JANGKA PENDEK YANG PANJANG

Terdapat kurang kajian mengenai ramalan harga saham menggunakan model LSTM (Ma, 2020). Berdasarkan kajian Sethia dan Raut (2020), dalam beberapa kajian yang membandingkan keputusan ramalan model LSTM dan rangkaian neural buatan (ANN),

boleh dibuat kesimpulan bahawa model LSTM mempunyai prestasi yang lebih baik dan perbezaan ini mungkin datang daripada penambahbaikan model LSTM mengenai masalah kecerunan lenyap. Ia juga mungkin disebabkan penambahan penunjuk untuk membantu membezakan antara turun naik harga pasaran dan turun naik tidak sengaja dalam pemboleh ubah input. Namun, model BNN hanya menggunakan siri masa untuk memuatkan data.

Jadual 4.7 menunjukkan perbandingan ketepatan peramalan harga saham menggunakan kaedah BNN dan LSTM. Berdasarkan Jadual 4.7, peramalan harga saham menggunakan kaedah LSTM lebih baik daripada kaedah BNN. Hal ini kerana kaedah LSTM mempunyai RMSE bernilai 0.028717 dan MAPE bernilai 3.915390 peratus lebih rendah daripada kaedah BNN iaitu RMSE bernilai 0.186804 dan MAPE bernilai 4.347436 peratus. Selain itu, nilai ketepatan ramalan menggunakan kaedah LSTM iaitu 93.793103 peratus lebih tinggi berbanding kaedah BNN iaitu 88.965517 peratus.

Jadual 4.7 Perbandingan ketepatan peramalan harga saham menggunakan kaedah BNN dan LSTM

	BNN	**LSTM**
RMSE	0.186804	0.028717
MAPE (%)	4.347436	3.915390
Ketepatan ramalan (%)	88.965517	93.793103



Rajah 4.4 Graf perbandingan ramalan harga saham antara BNN dan LSTM

Rajah 4.4 menunjukkan graf perbandingan ramalan harga saham antara BNN dan LSTM. Merujuk Rajah 4.4 dapat dilihat bahawa garisan graf peramalan harga saham menggunakan kaedah LSTM lebih menghampiri bacaan sebenar. Ini menunjukkan perbezaan besar antara ketepatan peramalan harga saham menggunakan kaedah BNN dan kaedah LSTM yang membuktikan bahawa algoritma LSTM lebih sesuai berbanding kaedah BNN.

BAB V

KESIMPULAN DAN CADANGAN

5.1 PENGENALAN

Bab ini akan menyimpulkan hasil kajian yang diperoleh daripada Bab IV. Secara tuntasnya, LSTM adalah antara kaedah yang sesuai digunakan dalam peramalan suatu indeks saham kerana ciri istimewanya yang mampu mengingati data input yang panjang selain dapat memproses banyak data siri masa dalam satu masa. Selain itu, kajian ini juga telah mencapai objektif kajian yang telah dicadangkan.

5.2 KESIMPULAN

Ramalan pasaran saham sangat sukar kerana sifatnya yang tidak linear, dinamik dan rumit. Namun, ia sangat penting kerana ramalan yang berjaya mempunyai beberapa faedah yang mempengaruhi keputusan peniaga kewangan mengenai pembelian atau penjualan instrumen kewangan. Antara faktor utama yang dipertimbangkan oleh pelabur dalam membuat pelaburan dan keputusan jual beli saham adalah indeks harga saham (Nikou, 2019). Kajian ini telah dijalankan untuk meramalkan harga saham syarikat Top Glove Malaysia. Untuk tujuan ini, dua teknik perlombongan data iaitu rambatan kebelakang dan LSTM telah dilaksanakan menggunakan perisian Python dan fungsinya dibandingkan dengan harga penutup harian Top Glove bermula 1 Jun 2018 hingga 30 Jun 2021.

Set data syarikat Top Glove terdiri daripada beberapa ciri seperti harga tinggi, harga rendah, harga buka, harga tutup dan jumlah saham yang didagangkan tetapi tidak mencukupi untuk melaksanakan peramalan lebih tepat. Bagi mendapatkan ketepatan yang lebih tinggi dalam nilai harga yang diramalkan, pemboleh ubah baru telah dicipta menggunakan pemboleh ubah sedia ada. BNN digunakan untuk meramalkan harga

saham pada hari berikutnya dan LSTM juga dilaksanakan untuk analisis perbandingan. Analisis perbandingan berdasarkan nilai RMSE dan MAPE jelas menunjukkan bahawa LSTM memberikan ramalan harga saham yang lebih baik berbanding BNN. Keputusan menunjukkan bahawa nilai terbaik yang diperoleh oleh model LSTM memberikan RMSE (0.028717) dan MAPE (3.915390).

5.3 CADANGAN

Cadangan untuk peramalan lebih tepat adalah menggunakan model gabungan seperti model regresi vektor sokongan gabungan dengan algoritma genetik dan model gabungan lain yang diambil daripada algoritma pembelajaran mesin. Selain itu, untuk penyelidikan lanjut adalah disyorkan untuk menyelidik pelbagai jenis model LSTM seperti LSTM bertindan, LSTM penyahkod-pengekod, LSTM dwiarah, CNN LSTM dan model LSTM generatif dalam ramalan harga saham.dan mempertimbangkan artikel berita kewangan bersama-sama dengan parameter kewangan seperti harga penutup, jumlah dagangan, penyata untung rugi dan sebagainya untuk hasil yang lebih baik.

RUJUKAN

Adebiyi, A.A. Adewumi, A.O. & Ayo, C.K. 2014. Comparison of ARIMA and artificial neural networks models for stock price prediction. *Journal of Applied Mathematics, 2014*.

Anggreani, D., Zaeni, I. A. E., Handayani, A. N., Azis, H., & Manga, A. R. 2021. Multivariate Data Model Prediction Analysis Using Backpropagation Neural Network Method. In *2021 3rd East Indonesia Conference on Computer and Information Technology (EIConCIT)*:239-243. IEEE.

BeBusinessed. 2019. History of The Stock Market. https://bebusinessed.com/history/history-of-the-stock-market/ [25 Januari 2022]

Brownlee, J. 2018. How to configure the number of layers and nodes in a neural network. Machine Learning Mastery: Vermont, Australia. https://machinelearningmastery.com/how-to-configure-the-number-of-layers-and-nodes-in-a-neural-network/ [25 Disember 2021]

Bursa Digital Research. 2021. Top Glove Corporation Berhad. https://www.bursamalaysia.com/sites/5bb54be15f36ca0af339077a/content_entry617bfd1c39fba20f54a06566/61c9138739fba27c7fb478b6/files/Bursa_Blitz_-_Top_Glove_-_24_December_2021.pdf?1640572008 [25 Januari 2022]

Chen, L., Qiao, Z., Wang, M., Wang, C., Du, R. & Stanley, H.E. 2018. Which artificial intelligence algorithm better predicts the Chinese stock market?. IEEE Access, 6, pp.48625-48633.

Chuan, T. B., Hameed, V. A., & Ramachandiran, C. R. 2021. Malaysia stock market prediction using artificial intelligence. *Journal of Applied Technology and Innovation (e-ISSN: 2600-7304)*, 5(1):32.

Ding, G. & Qin, L. 2020. Study on the prediction of stock price based on the associated network model of LSTM. International Journal of Machine Learning and Cybernetics, 11(6): 1307-1317.

Gao, Q. 2016. Stock market forecasting using recurrent neural network (Doctoral dissertation, University of Missouri--Columbia).

Guliyev, N.J. & Ismailov, V.E. 2018. Approximation capability of two hidden layer feedforward neural networks with fixed weights. Neurocomputing, 316: 262-269.

Hasan, N. & Rasel, R.I. 2016. Artificial neural network approach for stock price and trend prediction. In International Conference on Advanced Information & Communication Technology, Bangladesh.

Islam, M. R., & Nguyen, N. 2020. Comparison of Financial Models for Stock Price Prediction. *Journal of Risk and Financial Management*, 13(8): 181.

Kumar, M. & Thenmozhi, M. 2006. Forecasting stock index movement: A comparison of support vector machines and random forest. In Indian institute of capital markets 9th capital markets conference paper.

Liu, H. & Wang, J. 2011. Integrating independent component analysis and principal component analysis with neural network to predict chinese stock market. Mathematical Problems in Engineering 2011.

Ma, Q. 2020. Comparison of ARIMA, ANN and LSTM for stock price prediction. *E3S Web of Conferences* ,Vol. 218. EDP Sciences.

MATRADE. 2021. Top Glove. https://www.matrade.gov.my/brands/en/products/16-rubber-products/101-top-glove#:~:text=Founded%20in%201991%2C%20Top%20Glove,42%20billion%20gloves%20per%20annum [25 Januari 2022]

Moghaddam, A.H., Moghaddam, M.H. & Esfandyari, M. 2016. Stock market index prediction using artificial neural network. Journal of Economics, Finance and Administrative Science, 21(41): 89-93.

Moghaddam, A.H., Moghaddam, M.H. & Esfandyari, M. 2016. Stock market index prediction using artificial neural network. Journal of Economics, Finance and Administrative Science, 21(41), pp.89-93.

Müller, F. 2020. Stock Market Prediction using Multivariate Time Series and Recurrent Neural Networks in Python. https://www.relataly.com/stock-market-prediction-using-multivariate-time-series-in-python/1815/ [25 November 2021]

Mung, T. S. 2021 Top Glove's annual glove production capacity hits 100 billion pieces. https://www.theedgemarkets.com/article/top-gloves-annual-glove-production-capacity-hits-100-billion-pieces [10 Januari 2022]

Nikou, M., Mansourfar, G. & Bagherzadeh, J. 2019. Stock price prediction using DEEP learning algorithm and its comparison with machine learning algorithms. Intelligent Systems in Accounting, Finance and Management, 26(4), pp.164-174.

Nti, I. K., Adekoya, A. F., & Weyori, B. A. 2020. A comprehensive evaluation of ensemble learning for stock-market prediction. Journal of Big Data, 7(1): 1-40.

Olah, C. 2015. Understanding lstm networks. https://colah.github.io/posts/2015-08-Understanding-LSTMs/ [25 Disember 2021]

Oppermann, A. 2020. Stochastic-, Batch-, and Mini-Batch Gradient Descent Demystified. https://towardsdatascience.com/stochastic-batch-and-mini-batch-gradient-descent-demystified-8b28978f7f5 [20 Disember 2021]

Rajihy, Y., Nermend, K. & Alsakaa, A. 2017. Back-propagation artificial neural networks in stock market forecasting. an application to the Warsaw stock exchange WIG20. Aestimatio: The IEB International Journal of Finance (15): 88–99.

Ruxanda, G. & Badea, L.M. 2014. Configuring artificial neural networks for stock market predictions. Technological and Economic Development of Economy, 20(1): 116- 132.

Sagir, A.M. & Sathasivan, S. 2017. The use of artificial neural network and multiple linear regressions for stock market forecasting. MATEMATIKA: Malaysian Journal of Industrial and Applied Mathematics, 33(1): 1-10.

Sethia, A., & Raut, P. 2019. Application of LSTM, GRU and ICA for stock price prediction. *Information and Communication Technology for Intelligent Systems*: 479-487. Springer, Singapore.

Sidhpuri, M. 2021. All you need to know about Gradient Descent. https://medium.com/analytics-vidhya/all-you-need-to-know-about-gradient-descent-f0178c19131d [20 Disember 2021]

Singh, D. 2019. Neural Network In Python: Introduction, Structure and Trading Strategies. https://blog.quantinsti.com/neural-network-python/ [6 November 2021]

Song, Y. 2018. Stock Trend Prediction: Based on Machine Learning Methods. ProQuest Dissertations and Theses 43.

Staudemeyer, R. C. & Morris, E. R. 2019. Understanding LSTM--a tutorial into Long Short-Term Memory Recurrent Neural Networks. arXiv preprint arXiv:1909.09586.

Top Glove. 2021. The World's Largest Manufacturer of Gloves. https://www.topglove.com/home [10 Januari 2022]

Vijh, M., Chandola, D., Tikkiwal, V.A. & Kumar, A. 2020. Stock Closing Price Prediction using Machine Learning Techniques. Procedia Computer Science 167: 599–606.

Zhuge, Q., Xu, L. & Zhang, G. 2017. LSTM Neural Network with Emotional Analysis for prediction of stock price. Engineering letters, 25(2).

LAMPIRAN A

PENGATURCARAAN KOMPUTER

```
import numpy as np
import pandas as pd
from google.colab import files
uploaded = files.upload()

# Mengimport Data
import numpy as np
import pandas as pd
import io
data = pd.read_csv(io.BytesIO(uploaded['Top Glove New.csv']))

data.head(3)

data.shape

data.set_index('Date', inplace=True)
data.head()

#Graf Harga Saham Syarikat Top Glove
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Plot the close price
data['Price'].plot(figsize=(16,8))

# Define the label for the title of the figure
plt.title("Harga Saham Syarikat Top Glove", fontsize=20)

# Define the labels for x-axis and y-axis
plt.ylabel('Harga', fontsize=16)
plt.xlabel('Masa', fontsize=16)

# Plot the grid lines
plt.grid(which="major", color='#A3A3A3', linestyle='-', linewidth=0.5)

# Show the plot
plt.show()

# Set Data yang Digunakan

import numpy as np
import pandas as pd

# Setting the random seed to a fixed number
```

```
import random
random.seed(42)

# Importing the dataset
data = data[['Open', 'High', 'Low', 'Price']]

# Price is a Close Price
data.head()

#Pemboleh Ubah Baharu
# Preparing the new input variables in dataset
data['H-L'] = data['High'] - data['Low']
data['O-C'] = data['Price'] - data['Open']
data['3day MA'] = data['Price'].shift(1).rolling(window = 3).mean()
data['10day MA'] = data['Price'].shift(1).rolling(window = 10).mean()
data['30day MA'] = data['Price'].shift(1).rolling(window = 30).mean()
data['Std_dev']= data['Price'].rolling(5).std()


# Importing the dataset
dataset = data[['H-L', 'O-C', '3day MA', '10day MA', '30day MA', 'Std_dev', 'Price']]
dataset = dataset.dropna()
dataset

# Model BNN-ANN (Rambatan Kebelakang)
# Create two data frames storing the input and the output variables
x = dataset.iloc[:, 0:6]
y = dataset.iloc[:, -1]

print(x)
print(y)

# Get the number of rows to train the model
import math
training_data_len = math.ceil(len(dataset) * 0.8)
training_data_len

# Splitting the dataset
split = int(len(dataset)*0.8)
x_train, x_test, y_train, y_test = x[:split], x[split:], y[:split], y[split:]

print('x_train shape: {}'.format(x_train.shape))
print('y_train shape: {}'.format(y_train.shape))
print('x_test shape: {}'.format(x_test.shape))
print('y_test shape: {}'.format(y_test.shape))

# Feature Scaling
from sklearn.preprocessing import StandardScaler
sc = StandardScaler()
```

```
x_train = sc.fit_transform(x_train)
x_test = sc.transform(x_test)

# Build the Backpropagation
import tensorflow as tf

model = tf.keras.models.Sequential()

# Input layer ada 6 node kerana menggunakan 6 variable baru
model.add(tf.keras.layers.Dense(units=6))

# Hidden layer (tidak kesah letak node berapa)
model.add(tf.keras.layers.Dense(units=10))

# Output layer
model.add(tf.keras.layers.Dense(units=1))

# Compile the model
model.compile(optimizer='adam', loss='mean_squared_error')

# Train the model
model.fit(x_train, y_train, epochs=100, batch_size=64)

model.summary()

# Get the models predicted price values
predictions = model.predict(x_test)
predictions.shape

# Plot the data BNN
train = dataset[:training_data_len]
valid = dataset[training_data_len:]
valid['Predictions'] = predictions

# Visualize the data
plt.figure(figsize=(16,7))
plt.title('Ramalan Harga Saham Menggunakan BNN', fontsize=20)
plt.xticks(np.arange(0,755,100))
plt.xlabel('Masa', fontsize=16)
plt.ylabel('Harga', fontsize=16)
plt.plot(train['Price'])
plt.plot(valid[['Price', 'Predictions']])
plt.legend(['Latih', 'Asal', 'Ramalan BNN'], loc='upper right')

# Plot the grid lines
plt.grid(which="major", color='#A3A3A3', linestyle='-', linewidth=0.5)
plt.show()
```

```
data_bp = dataset
data_bp['predictions'] = np.NaN
data_bp.iloc[(len(dataset) - len(predictions)):,-1:] = predictions
trade_data = data_bp.dropna()
trade_data

trade_data.describe()

predictions.ndim

y_test.ndim

predictions_1d = predictions.flatten()

# Get the Root Mean Square Error (RMSE)
RMSE = np.sqrt(np.mean(predictions_1d - y_test) ** 2)

# Get the Mean Absolute Percentage Error (MAPE)
MAPE = np.mean(np.abs((y_test - predictions_1d) / y_test)) * 100

print('RMSE (BNN): {}'.format(RMSE))
print('MAPE (BNN): {}'.format(MAPE))

# Confusion Matrix (Rambatan Kebelakang)
from sklearn.metrics import confusion_matrix
cutoff = 5.5                              # decide on a cutoff limit
y_pred_classes = np.zeros_like(predictions)    # initialise a matrix full with zeros
y_pred_classes[predictions > cutoff] = 1       # add a 1 if the cutoff was breached

y_test_classes = np.zeros_like(predictions)
y_test_classes[y_test > cutoff] = 1

confusion_matrix(y_test_classes, y_pred_classes)


from sklearn.metrics import confusion_matrix
TP, TN, FP, FN = confusion_matrix(y_test_classes, y_pred_classes).ravel()

print('True Positive :', TP)
print('True Negative :', TN)
print('False Positive :', FP)
print('False Negative :', FN)

from sklearn.metrics import classification_report
print(classification_report(y_test_classes, y_pred_classes))

print('BNN')

from sklearn.metrics import accuracy_score
```

```
print('Accuracy :', 100 * accuracy_score(y_test_classes, y_pred_classes))

from sklearn.metrics import precision_score
print('Precision :', 100* precision_score(y_test_classes, y_pred_classes))

from sklearn.metrics import recall_score
print('Recall :', 100* recall_score(y_test_classes, y_pred_classes))

from sklearn.metrics import f1_score
print('F1 score :', f1_score(y_test_classes, y_pred_classes))



#Memori Jangka Pendek yang Panjang (LSTM)
import math # Mathematical functions
import numpy as np # Fundamental package for scientific computing with Python
import pandas as pd # Additional functions for analysing and manipulating data
from datetime import date, timedelta, datetime # Date Functions
import matplotlib.pyplot as plt
import matplotlib.dates as mdates # Formatting dates
from sklearn.metrics import mean_absolute_error, mean_squared_error
from keras.models import Sequential
from keras.layers import LSTM, Dense, Dropout # Deep learning classes for recurrent
and regular densely-connected layers
from keras.callbacks import EarlyStopping # EarlyStopping during model training
from sklearn.preprocessing import MinMaxScaler


# Preprocessing and Feature Selection

# Indexing Batches
dataset = data[['H-L', 'O-C', '3day MA', '10day MA', '30day MA', 'Std_dev', 'Price']]
dataset = dataset.dropna()
dataset
train_df = dataset.sort_values(by=['Date']).copy()

# We safe a copy of the dates index, before we need to reset it to numbers
date_index = train_df.index

# We reset the index, so we can convert the date-index to a number-index
train_df = train_df.reset_index(drop=True).copy()
train_df.head(5)

train_df.shape


# List of considered Features
FEATURES = ['H-L', 'O-C', '3day MA', '10day MA', '30day MA', 'Std_dev', 'Price']
```

```
print('FEATURE LIST')
print([f for f in FEATURES])

# Create the dataset with features and filter the data to the list of FEATURES
data2 = pd.DataFrame(train_df)
data_filtered = data2[FEATURES]

# We add a prediction column and set dummy values to prepare the data for scaling
data_filtered_ext = data_filtered.copy()
data_filtered_ext['Prediction'] = data_filtered_ext['Price']

# Print the tail of the dataframe
data_filtered_ext.tail()


# Get the number of rows in the data
nrows = data_filtered.shape[0]

# Convert the data to numpy values
np_data_unscaled = np.array(data_filtered)
np_data = np.reshape(np_data_unscaled, (nrows, -1))
print('np_data: {}'.format(np_data.shape))

# Transform the data by scaling each feature to a range between 0 and 1
scaler = MinMaxScaler()
np_data_scaled = scaler.fit_transform(np_data_unscaled)

# Creating a separate scaler that works on a single column for scaling predictions
scaler_pred = MinMaxScaler()
df_Close = pd.DataFrame(data_filtered_ext['Price'])
np_Close_scaled = scaler_pred.fit_transform(df_Close)


# Set the sequence length - this is the timeframe used to make a single prediction
sequence_length = 60

# Prediction Index
index_Close = data2.columns.get_loc("Price")

# Split the training data into train and train data sets
# As a first step, we get the number of rows to train the model on 80% of the data
train_data_len = math.ceil(np_data_scaled.shape[0] * 0.8)

# Create the training and test data
train_data = np_data_scaled[0:train_data_len, :]
test_data = np_data_scaled[train_data_len - sequence_length:, :]

# The RNN needs data with the format of [samples, time steps, features]
# Here, we create N samples, sequence_length time steps per sample, and 6 features
```

```
def partition_dataset(sequence_length, data2):
    X, Y = [], []
    data_len = data2.shape[0]
    for i in range(sequence_length, data_len):
        X.append(data2[i-sequence_length:i,:]) #contains sequence_length values 0-sequence_length * columns
        Y.append(data2[i, index_Close]) #contains the prediction values for validation, for single-step prediction

    # Convert the x and y to numpy arrays
    X = np.array(X)
    Y = np.array(Y)
    return X, Y

# Generate training data and test data
X_train, Y_train = partition_dataset(sequence_length, train_data)
X_test, Y_test = partition_dataset(sequence_length, test_data)

# Print the shapes: the result is: (rows, training_sequence, features) (prediction value, )
print('X_train shape: {}'.format(X_train.shape))
print('Y_train shape: {}'.format(Y_train.shape))
print('X_test shape: {}'.format(X_test.shape))
print('Y_test shape: {}'.format(Y_test.shape))

# Validate that the prediction value and the input match up
# The last close price of the second input sample should equal the first prediction value
print('The last close price of the second input sample should equal the first prediction value:')
print(X_train[1][sequence_length-1][index_Close])
print(Y_train[0])


# Model Training (LSTM)
import tensorflow as tf

# Configure the neural network model
model = tf.keras.models.Sequential()

# Model with n_neurons = inputshape Timestamps, each with x_train.shape[2] variables
n_neurons = X_train.shape[1] * X_train.shape[2]
print('n_neurons: {}'.format(n_neurons))
print('X_train.shape[1]: {}'.format(X_train.shape[1]))
print('X_train.shape[2]: {}'.format(X_train.shape[2]))

model.add(LSTM(n_neurons, return_sequences=True, input_shape=(X_train.shape[1], X_train.shape[2])))
model.add(LSTM(n_neurons, return_sequences=False))
model.add(Dense(10))
```

```
model.add(Dense(1))

# Compile the model
model.compile(optimizer=tf.keras.optimizers.Adam(), loss='mse')

model.summary()


# Training the LSTM model
epochs = 100
batch_size = 64
early_stop = EarlyStopping(patience=5, verbose=1)
history = model.fit(X_train, Y_train,
                    batch_size=batch_size,
                    epochs=epochs,
                    validation_data=(X_test, Y_test))


# Evaluate Model Performance

# Get the predicted values
Y_pred_scaled = model.predict(X_test)
Y_pred_scaled.shape

# Unscale the predicted values
Y_pred = scaler_pred.inverse_transform(Y_pred_scaled)
Y_test_unscaled = scaler_pred.inverse_transform(Y_test.reshape(-1, 1))

Y_pred_scaled.shape


# Add the date column
data_filtered_sub = data_filtered.copy()
data_filtered_sub['Date'] = date_index

# Add the difference between the valid and predicted prices
train = data_filtered_sub[:train_data_len + 1]
valid = data_filtered_sub[train_data_len:]
valid.insert(1, "Prediction", Y_pred.ravel(), True)
valid.insert(1, "Difference", valid["Prediction"] - valid["Price"], True)

# Visualize the data
plt.figure(figsize=(16,7))
plt.title('Ramalan Harga Saham Menggunakan LSTM', fontsize=20)
plt.xticks(np.arange(0,755,100))
plt.xlabel('Masa', fontsize=16)
plt.ylabel('Harga', fontsize=16)
plt.plot(train['Date'], train[["Price"]])
plt.plot(valid['Date'], valid[["Price", "Prediction"]])
```

```
plt.legend(['Latih', 'Asal', 'Ramalan LSTM'], loc='upper right')

# Plot the grid lines
plt.grid(which="major", color='#A3A3A3', linestyle='-', linewidth=0.5)
plt.show()


train_df['Y_pred'] = np.NaN
train_df.iloc[(len(train_df) - len(Y_pred)):,-1:] = Y_pred
trade_data2 = train_df.dropna()
trade_data2

trade_data2.describe()

# Get the Root Mean Square Error (RMSE)
rmse = np.sqrt(np.mean(Y_pred - Y_test_unscaled) ** 2)

# Get the Mean Absolute Percentage Error (MAPE)
mape = np.mean(np.abs((Y_test_unscaled - Y_pred) / Y_test_unscaled)) * 100

print('RMSE (LSTM): {}'.format(rmse))
print('MAPE (LSTM): {}'.format(mape))

# Confusion Matrix (LSTM)
from sklearn.metrics import confusion_matrix
cutoff = 5.5                              # decide on a cutoff limit
Y_pred_classes = np.zeros_like(Y_pred)    # initialise a matrix full with zeros
Y_pred_classes[Y_pred > cutoff] = 1       # add a 1 if the cutoff was breached

Y_test_classes = np.zeros_like(Y_pred)
Y_test_classes[Y_test_unscaled > cutoff] = 1

confusion_matrix(Y_test_classes, Y_pred_classes)


from sklearn.metrics import confusion_matrix
Tp, Tn, Fp, Fn = confusion_matrix(Y_test_classes, Y_pred_classes).ravel()

print('True Positive :', Tp)
print('True Negative :', Tn)
print('False Positive :', Fp)
print('False Negative :', Fn)

from sklearn.metrics import classification_report
print(classification_report(Y_test_classes, Y_pred_classes))

print('LSTM')

from sklearn.metrics import accuracy_score
```

```
print('Accuracy :', 100 * accuracy_score(Y_test_classes, Y_pred_classes))

from sklearn.metrics import precision_score
print('Precision :', 100* precision_score(Y_test_classes, Y_pred_classes))

from sklearn.metrics import recall_score
print('Recall :', 100* recall_score(Y_test_classes, Y_pred_classes))

from sklearn.metrics import f1_score
print('F1 score :', f1_score(Y_test_classes, Y_pred_classes))


#Graf Perbandingan Keseluruhan
# Add the date column
data_filtered_sub = data_filtered.copy()
data_filtered_sub['Date'] = date_index

# Add the difference between the valid and predicted prices
train = data_filtered_sub[:train_data_len + 1]
valid = data_filtered_sub[train_data_len:]
valid.insert(1, "Prediction_LSTM", Y_pred.ravel(), True)
valid.insert(1, "Difference", valid["Prediction_LSTM"] - valid["Price"], True)
valid.insert(1, "Prediction_BP", predictions.ravel(), True)
valid.insert(1, "Difference", valid["Prediction_BP"] - valid["Price"], True)

# Visualize the data
plt.figure(figsize=(16,7))
plt.title('Perbandingan Ramalan Harga Saham', fontsize=20)
plt.xticks(np.arange(0,755,100))
plt.xlabel('Masa', fontsize=16)
plt.ylabel('Harga', fontsize=16)
plt.plot(train['Date'], train[["Price"]])
plt.plot(valid['Date'], valid[["Price", "Prediction_BP","Prediction_LSTM"]])
plt.legend(['Latih', 'Asal', 'BNN', 'LSTM'], loc='upper right')

# Plot the grid lines
plt.grid(which="major", color='#A3A3A3', linestyle='-', linewidth=0.5)
plt.show()
```